
Predicción del Peso Final de Pollos de Engorde

Un pipeline reproducible de Ciencia de Datos para la toma de decisiones
en planta avícola

Informe técnico del caso práctico

De la limpieza del dato a la conclusión capitalizable

Objetivo. Construir y validar un modelo capaz de *predecir el peso final* de un lote de pollos de engorde a partir de variables de manejo, ambiente y genética, y traducir el modelo en **recomendaciones operativas auditables**: qué línea genética conviene, qué variables gobiernan el engorde, cuánto alimento se consume y dónde está el dinero.

Trabajo desarrollado íntegramente en Python (*scikit-learn*, *statsmodels*, *XGBoost*, *LightGBM*). Cuaderno reproducible con semilla fija (`random_state = 42`).

Ecuador — 2026

Índice

1. Resumen ejecutivo	2
2. Datos y metodología	2
2.1. El conjunto de datos	2
2.2. Hoja de ruta del análisis	2
3. Comprensión y limpieza del dato	3
3.1. Calidad de los datos	3
3.2. Faltantes y valores atípicos	3
3.3. Ingeniería de características (documentada)	3
4. Análisis exploratorio de datos (EDA)	3
4.1. La curva de crecimiento	4
4.2. Estructura de correlación e información	4
4.3. Distribuciones y dispersión por grupos	6
4.4. Análisis de componentes principales (PCA)	7
5. Selección de variables	7
5.1. Control de fuga de información (<i>data leakage</i>)	7
5.2. Variables seguras y su capacidad incremental	7
6. Modelado y comparación de métricas	8
6.1. Diseño experimental	8
6.2. Banco de modelos y resultados	8
6.3. Modelo campeón y principio de parsimonia	9
7. Importancia de variables y hallazgos de negocio	10
7.1. Importancia por permutación	10
7.2. Efecto ajustado de la línea genética	11
7.3. Peso a faena y consumo por línea	11
7.4. Traducción económica (monetización auditable)	12
7.5. Sobre el FCR (conversión alimenticia)	12
8. Conclusiones capitalizables y auditables	12
9. Recomendaciones	12
10. Limitaciones	13
11. Referencias y fuentes auditables	13

1. Resumen ejecutivo

Se analizó un conjunto de 1000 registros de lotes de pollos de engorde con 11 variables, con el fin de predecir el **peso final** (g) y extraer conclusiones útiles para la operación. El trabajo siguió un pipeline completo y reproducible: comprensión del dato, limpieza, análisis exploratorio (EDA), selección de variables con control estricto de *fuga de información*, comparación de once modelos —estadísticos y de *machine learning*— y análisis de importancia con lectura de negocio.

Los resultados principales son:

- **El crecimiento es esencialmente lineal en la ventana de cría (1–42 días).** La edad explica por sí sola el 98,1 % de la varianza del peso final; añadir el consumo de alimento, el sexo, la línea genética y el ambiente aporta mejoras marginales.
- **Modelo campeón: regresión Lasso** (lineal regularizada), con **RMSE** de 83,08 g, **MAE** de 64,58 g, $R^2 = 0,9921$ y **MAPE** de 5,82 % sobre datos de prueba no vistos. Los modelos de árboles (XGBoost, LightGBM, Random Forest) *no* superaron a la familia lineal: se eligió el modelo más simple, interpretable y desplegable (principio de parsimonia).
- **El sexo pesa más que la genética.** Controlando edad y línea, los machos pesan en promedio 126,4 g más que las hembras (IC 95 %: 113,2 a 139,7).
- **Ranking de líneas (efecto ajustado por edad y sexo): Cobb 500** encabeza con 44,3 g (IC 95 %: 28,1 a 60,5) sobre Arbor Acres, seguida de **Ross 308** con 25,2 g (IC 95 %: 9,1 a 41,4). Ambos efectos son estadísticamente significativos y coinciden con la literatura para clima tropical.
- **Impacto económico.** A precio de mercado de referencia (1,65 USD/k en pie), migrar un lote de 10 000 aves a Cobb 500 frente a Arbor Acres añade del orden de 1481 USD **por lote** en ingreso bruto solo por mayor peso.
- **Las variables ambientales (temperatura, humedad, mortalidad) aparecen como ruido** en este dataset (información mutua nula con el objetivo). Es un *hallazgo de calidad del dato*, no una verdad biológica: la literatura sí documenta su efecto. Se recomienda mejorar la sensórica y el registro para capitalizar esa señal.

2. Datos y metodología

2.1. El conjunto de datos

La base contiene 1000 observaciones (lotes) y 11 columnas. La variable objetivo es `Peso_Final_g`. El resto se agrupa en cuatro bloques: *tiempo* (`Edad_Dias`), *manejo/ambiente* (`Consumo_Alimento_g_dia`, `Temperatura_C`, `Humedad_%`, `Densidad_Aves_m2`, `Mortalidad_%`), *biología* (`Sexo`, `Linea_Genetica`, `Peso_Inicial_g`) e *identificación* (`ID_Lote`).

2.2. Hoja de ruta del análisis

El pipeline implementado en el cuaderno `pipeline_pollos.ipynb` cubre, en orden, las siete etapas del encargo: (1) conocer el dato, (2) preparar el terreno —limpieza, faltantes, *outliers*, ingeniería de variables—, (3) EDA, (4) selección de variables, (5) modelado, (6) comparación de métricas y (7) importancia de variables y recomendaciones. Todo el flujo es reproducible con semilla fija y los artefactos (figuras y tablas) se persisten automáticamente en `outputs/`.

3. Comprensión y limpieza del dato

3.1. Calidad de los datos

La auditoría de calidad fue, en buena medida, una buena noticia: **no hay valores nulos, ni duplicados, ni centinelas** (códigos del tipo $-1/999$ usados para marcar ausencias). El único “999” presente corresponde a un `ID_Lote` legítimo dentro de una secuencia 1 a 1000. Las clases categóricas están balanceadas: sexo $\approx 50/50$ y las tres líneas genéticas con ≈ 330 lotes cada una. La Tabla 1 resume el diagnóstico.

Tabla 1: Diagnóstico de calidad y rango de las variables.

Variable	Tipo	Nulos	Únicos	Mín.	Máx.
Edad_Dias	entero	0	42	1,00	42,00
Consumo_Alimento_g_dia	decimal	0	771	20,00	231,10
Temperatura_C	decimal	0	141	20,00	34,00
Humedad_%	decimal	0	376	45,00	85,00
Densidad_Aves_m2	decimal	0	101	8,00	18,00
Mortalidad_%	decimal	0	406	0,00	6,48
Peso_Inicial_g	decimal	0	101	38,00	48,00
Peso_Final_g (objetivo)	decimal	0	975	135,00	3596,30

3.2. Faltantes y valores atípicos

Dado que no existen faltantes, no fue necesaria imputación; aun así, el preprocesamiento incluye imputación por mediana (numéricas) y moda (categóricas) como *salvaguarda* para datos futuros en producción. En cuanto a *outliers*, el análisis sobre la curva de crecimiento mostró apenas dos puntos con $|z| > 3$ y ninguno con $|z| > 4$. **No se eliminó ni se winsorizó ningún registro:** los puntos extremos siguen el patrón general (aves muy jóvenes o muy próximas a faena) y eliminarlos sesgaría el modelo.

Hallazgo. El dato presenta un **artefacto de origen sintético**: a día 1 el peso medio ronda los 373 g, biológicamente imposible para un pollito BB (que pesa 40 g a 45 g, coherente con `Peso_Inicial_g`). La recta de crecimiento tiene un intercepto no físico (≈ 260 g). Se documenta como **limitación** y no se “corrige”, para no introducir supuestos no verificables.

3.3. Ingeniería de características (documentada)

Siguiendo el criterio de *incluir una variable solo si aporta a la predicción*, se crearon tres variables y se evaluó su contribución (Sección 5):

- `Edad_Dias_sq = Edad_Dias2`: captura una eventual curvatura sigmoidea del crecimiento (modelo de Gompertz).
- `THI` (*Temperature-Humidity Index*, Thom 1959): $THI = (1,8T + 32) - (0,55 - 0,0055RH)(1,8T - 26)$, índice estándar de estrés térmico que condensa temperatura y humedad en una sola señal.
- `Sexo_macho`: codificación binaria del sexo.

4. Análisis exploratorio de datos (EDA)

4.1. La curva de crecimiento

El peso final crece de forma marcadamente lineal con la edad (Figura 1). El ajuste $\text{Peso} \approx 259,7 + 74,1 \cdot \text{Edad}$ alcanza $R^2 = 0,981$, y el término cuadrático es despreciable (coeficiente $\approx -0,009$). Es decir, **cada día de cría añade ≈ 74 g en promedio dentro de la ventana observada.**




Figura 1: Curva de crecimiento: peso final frente a edad, con ajuste lineal. El crecimiento es prácticamente recto en el rango 1–42 días.

4.2. Estructura de correlación e información

El mapa de correlaciones (Figura 2) confirma que **edad** ($r = 0,99$) y **consumo de alimento** ($r = 0,96$) dominan la relación con el peso, pero también que ambas están fuertemente correlacionadas entre sí ($r = 0,95$): aportan información en buena medida redundante. Las variables ambientales muestran correlación ≈ 0 con el objetivo.




Figura 2: Matriz de correlación de Pearson entre variables numéricas y el objetivo.

Para no quedarnos solo con relaciones lineales, se calculó la **información mutua** (Figura 3), que captura dependencias de cualquier forma. El resultado es contundente y a la vez revelador:




Figura 3: Información mutua de cada variable con el peso final. Edad y consumo concentran la señal; temperatura, humedad y mortalidad aportan prácticamente cero.

Hallazgo. Temperatura, humedad y mortalidad tienen información mutua exactamente nula con el objetivo: no hay señal ni lineal ni no lineal. Esto contradice la biología conocida (el estrés térmico afecta el engorde), por lo que se interpreta como un **problema de calidad/registro del dato**, no como evidencia de que el ambiente sea irrelevante. La recomendación operativa es reforzar la sensorica y el registro ambiental por galpón.

4.3. Distribuciones y dispersión por grupos

Las distribuciones de las variables clave (Figura 4) son regulares y sin colas anómalas. El diagrama de dispersión edad–peso segmentado por sexo y línea (Figura 5) muestra visualmente lo que después confirma el modelo: los machos se sitúan por encima de las hembras y Cobb 500 encabeza la nube de puntos en la zona de faena.




Figura 4: Distribuciones de las principales variables numéricas.




Figura 5: Peso final frente a edad, diferenciado por sexo y por línea genética.

4.4. Análisis de componentes principales (PCA)

El PCA (Figura 6) resume la geometría del problema: las dos primeras componentes capturan la mayor parte de la varianza, y el *biplot* muestra los vectores de edad y consumo casi superpuestos (redundancia) y apuntando en la dirección de máximo peso. El PCA aquí cumple un rol **diagnóstico** —evidenciar colinealidad y la dimensionalidad efectiva del problema— más que de reducción para el modelo final.




Figura 6: PCA: varianza explicada acumulada y *biplot* de cargas sobre las dos primeras componentes.

5. Selección de variables

5.1. Control de fuga de información (*data leakage*)

Este es el punto metodológico más delicado del caso, tenemos que demostrar por qué algunas variables constituyen *data leakage*. Variables como la **ganancia de peso**, la **ganancia diaria (GDP)** o el **índice de conversión alimenticia (FCR)** se derivan directamente del peso final. Usarlas como predictoras produciría un modelo con métricas espectaculares pero **inútil en producción**, porque en el momento de predecir todavía no se conoce el peso final. Por ello se aislaron en un objeto de *descriptores de negocio* y **nunca** entraron al modelo. Solo se usaron como lectura económica a posteriori.

5.2. Variables seguras y su capacidad incremental

El conjunto de predictoras seguras quedó en: numéricas {Edad, Consumo, Temperatura, Humedad, Densidad, Mortalidad, Peso_Inicial, Edad², THI} y categóricas {Sexo, Línea genética}. Para cuantificar *cuánto aporta cada bloque* se midió el R^2 de validación cruzada al ir añadiendo variables de forma acumulada (Figura 7 y Tabla 2).




Figura 7: Capacidad predictiva incremental (R^2 en validación cruzada) al añadir bloques de variables.

Tabla 2: Capacidad predictiva incremental por bloque de variables.

Conjunto de variables	R^2 (CV)
Solo Edad	0,9808
+ Consumo	0,9856
+ Sexo	0,9905
+ Línea genética	0,9907
+ Ambiente / Peso inicial	0,9914
+ Ingeniería (Edad², THI)	0,9913

Hallazgo. La edad sola ya alcanza $R^2 = 0,981$. El **segundo factor más rentable es el sexo** (salto a 0,990), por encima de la línea genética. El ambiente y la ingeniería de variables aportan mejoras marginales o nulas, coherente con el carácter lineal y sintético del dato. **Esto justifica preferir un modelo lineal y parsimonioso.**

6. Modelado y comparación de métricas

6.1. Diseño experimental

Se aplicó una partición **80/20 estratificada por quintiles de edad** para que train y test cubran todo el ciclo de cría. El preprocesamiento se encapsuló en un `ColumnTransformer` dentro de un `Pipeline` (imputación + estandarización para numéricas; imputación + *one-hot* con `drop='first'` para categóricas), evitando cualquier fuga del conjunto de prueba. La comparación se hizo con **validación cruzada de 5 particiones** usando el RMSE como criterio.

6.2. Banco de modelos y resultados

Se evaluaron once modelos, desde un *baseline* trivial (predecir la media) hasta *gradient boosting*. La Tabla 3 y la Figura 8 resumen el desempeño.

Tabla 3: Comparación de modelos por validación cruzada (5 particiones), ordenados por RMSE.

Modelo	RMSE (g)	$\pm$ sd	MAE (g)	R^2 (CV)
Lasso (campeón)	85,16	3,04	68,09	0,9910
Regresión Lineal	85,19	3,04	68,11	0,9910
Ridge	85,34	3,13	68,28	0,9910
ElasticNet	86,52	3,20	69,47	0,9907
Gradient Boosting	89,70	2,49	71,16	0,9900
XGBoost	92,62	3,13	73,80	0,9893
LightGBM	93,12	3,74	74,59	0,9892
Random Forest	104,04	4,99	81,98	0,9865
SVR (RBF)	145,13	7,13	109,95	0,9738
KNN ($k = 10$)	193,72	6,88	155,14	0,9536
Baseline (media)	902,80	26,33	783,06	-0,0059




Figura 8: RMSE en validación cruzada por modelo (menor es mejor). La familia lineal lidera.

6.3. Modelo campeón y principio de parsimonia

Los cuatro mejores modelos son lineales y están prácticamente empatados (RMSE entre 85,2 y 86,5 g). Los métodos de árboles, pese a su flexibilidad, **no superan** a la regresión y muestran mayor varianza. Ante un empate técnico, se eligió la **regresión Lasso** por su simplicidad, su capacidad de regularización (puede llevar coeficientes irrelevantes a cero, reforzando la interpretabilidad) y su facilidad de despliegue y mantenimiento.

Desempeño del campeón sobre el conjunto de prueba (datos no vistos):

Tabla 4: Métricas finales del modelo Lasso sobre el conjunto de prueba (20 %).

Métrica	Valor
RMSE (g)	83,08
MAE (g)	64,58
R^2	0,9921
MAPE (%)	5,82

El diagnóstico de residuos (Figura 9) confirma un buen ajuste: los predichos siguen la diagonal frente a los observados y los residuos se reparten sin estructura evidente alrededor de cero.




Figura 9: Diagnóstico del modelo campeón: valores predichos frente a observados y análisis de residuos.

7. Importancia de variables y hallazgos de negocio

7.1. Importancia por permutación

Para una lectura *agnóstica al modelo*, se calculó la importancia por permutación sobre el conjunto de prueba (Figura 10). El resultado es consistente con todo lo anterior: **la edad es, con diferencia, la variable más determinante**, seguida del consumo de alimento; el sexo aparece como el factor categórico de mayor peso.




Figura 10: Importancia de variables por permutación (caída del desempeño al permutar cada variable).

7.2. Efecto ajustado de la línea genética

Comparar el peso medio crudo por línea sería engañoso, porque las líneas podrían no estar igualmente distribuidas en edad y sexo. Por eso se estimó el **efecto ajustado** mediante una regresión (MCO/*OLS*) que controla edad y sexo ($R^2 = 0,986$), reportando intervalos de confianza al 95 % (Tabla 5). Esta es la forma correcta y auditable de responder “¿qué línea engorda más?”.

Tabla 5: Efecto ajustado sobre el peso final (g), controlando edad y sexo. Categorías base: Arbor Acres y Hembra.

Factor	Efecto (g)	IC 95 % inf.	IC 95 % sup.
Sexo: Macho	126,4	113,2	139,7
Línea: Cobb 500	44,3	28,1	60,5
Línea: Ross 308	25,2	9,1	41,4

Hallazgo. Cobb 500 es la línea que más engorda (44,3 g sobre Arbor Acres, ajustado), seguida de Ross 308 (25,2 g). Ambos efectos son significativos (sus IC no cruzan cero). Sin embargo, el **efecto del sexo** (126,4 g) casi triplica al de la mejor línea: la estrategia de sexado y manejo diferenciado por sexo es, en peso, más palanca que la elección de línea.

7.3. Peso a faena y consumo por línea

Mirando solo lotes próximos a faena (≥ 35 días), el peso medio observado ordena a las líneas igual que el efecto ajustado, con un consumo de alimento por día muy similar entre ellas (Tabla 6). Es decir, Cobb 500 logra más peso *sin* un consumo diario marcadamente mayor.

Tabla 6: Peso a faena (≥ 35 días) y consumo medio por línea genética.

Línea	Peso medio (g)	Consumo (g/día)	<i>n</i> lotes
Cobb 500	3172	190,68	66
Ross 308	3097	188,42	60
Arbor Acres	3082	184,88	62

7.4. Traducción económica (monetización auditable)

Para convertir gramos en dólares se usaron referencias **públicas y verificables** del mercado ecuatoriano (ver Sección 11): precio del pollo en pie de referencia 1,65 USD/k (rango de sensibilidad 1,45 USD/k a 1,85 USD/k). Bajo este supuesto y un lote tipo de 10 000 aves, el diferencial de peso de Cobb 500 frente a Arbor Acres se traduce en del orden de 1481 USD **de ingreso bruto adicional por lote**; Ross 308 aporta unos 254 USD por lote (Tabla 7). Es una estimación de *ingreso* por mayor peso; el margen neto dependería del costo del balanceado (referencia maíz amarillo $\approx$ 0,428 USD/k) y del FCR real de cada línea.

Tabla 7: Impacto económico estimado por lote de 10 000 aves (precio en pie 1,65 USD/k).

Línea	Peso (kg)	Δ kg vs base	Δ USD/lote
Cobb 500	3,172	0,090	1481
Ross 308	3,097	0,015	254
Arbor Acres	3,082	0,000	0

7.5. Sobre el FCR (conversión alimenticia)

El dataset registra consumo *diario* pero no *acumulado*, por lo que el FCR verdadero (alimento total / ganancia total) no es computable de forma exacta. El consumo diario similar entre líneas (Tabla 6) sugiere que Cobb 500 convierte al menos tan bien como las demás, pero **esta conclusión queda pendiente de validación** con consumo acumulado por fase.

8. Conclusiones capitalizables y auditables

1. **El peso final es altamente predecible.** Con un modelo lineal simple se obtiene $R^2 = 0,9921$ y un error porcentual medio de apenas 5,82 % en datos no vistos. La planta puede estimar el peso de faena de un lote con buena precisión a partir de variables que conoce *antes* de pesar.
2. **La edad y el consumo gobiernan el engorde;** el resto de variables ajusta en los márgenes. Esto orienta el control operativo hacia el cumplimiento de la curva de crecimiento por edad.
3. **Para maximizar peso, la palanca número uno es el sexo** (126 g machos) y la número dos es elegir **Cobb 500** (44 g ajustado), seguida de Ross 308 (25 g). Ambas conclusiones son estadísticamente sólidas (IC al 95 %) y coinciden con la literatura para clima tropical.
4. **Cobb 500 conviene cuando el objetivo es peso/volumen**, y lo logra con un consumo diario comparable al de las otras líneas, lo que la hace la mejor candidata para engorde en el contexto ecuatoriano —sujeto a confirmar FCR con datos de consumo acumulado—.
5. **Hay dinero medible en la decisión genética:** del orden de 1481 USD por lote de 10 000 aves al migrar a Cobb 500 frente a Arbor Acres, solo por mayor peso.

9. Recomendaciones

1. **Adoptar Cobb 500 como línea preferente para engorde**, priorizando lotes de machos cuando el mercado premie el peso, y monitorear el FCR real para confirmar la ventaja económica.
2. **Mejorar la captura de datos ambientales.** La señal nula de temperatura, humedad y mortalidad es un problema de medición, no una verdad biológica. Instalar/calibrar sensores por galpón y registrar a mayor frecuencia permitirá capitalizar esa información en el modelo.

3. **Registrar consumo de alimento acumulado por fase** (iniciador, crecimiento, engorde) para habilitar un módulo de FCR y de *margen por lote* automático.
4. **Desplegar el modelo lineal** como estimador de peso de faena (es ligero, interpretable y auditable) e integrarlo con precios de mercado por fecha para proyectar ingresos por lote.
5. **Incorporar marca temporal de lote** para migrar, a futuro, a una validación *out-of-time* que simule fielmente el despliegue.

10. Limitaciones

- **Dato sintético y lineal:** la relación peso–edad es lineal con intercepto no físico; un dataset real (curva de Gompertz) exigiría términos no lineales, ya habilitados en el pipeline (Edad_Dias_sq).
- **Ambiente sin señal:** probablemente por la forma en que se generaron/registrarón los datos; no debe leerse como ausencia de efecto biológico.
- **FCR aproximado:** sin consumo acumulado, el índice de conversión real no es calculable.
- **Precios externos:** la monetización usa referencias de mercado auditables, no precios internos de la empresa; los valores absolutos deben recalibrarse con datos propios.

11. Referencias y fuentes auditables

Literatura sobre líneas genéticas (rendimiento comparado)

Referencias

- [1] Estudio comparativo de desempeño en pollos de engorde (Cobb 500, Ross 308 y otras líneas), *ScienceDirect*, 2025. Reporta superioridad de Cobb 500 en peso corporal, ganancia de peso y conversión alimenticia. Disponible en: <https://www.sciencedirect.com/science/article/pii/S000390982500284X>
- [2] *Animal Research International* (AJOL). Comparación de rendimiento entre líneas comerciales en clima tropical: Cobb 500 alcanza el mayor peso corporal final frente a Arbor Acre y Ross 308. Disponible en: <https://www.ajol.info/index.php/ari/article/view/239731>
- [3] Comparativa técnica Cobb 500 vs. Ross 308 (parámetros productivos y de conversión). *Fidar Feed*. Disponible en: <https://fidarfeed.com/>
- [4] Thom, E.C. (1959). *The Discomfort Index* (Temperature–Humidity Index, THI). *Weatherwise*, 12(2), 57–61. Base del índice de estrés térmico empleado en la ingeniería de variables.

Fuentes de precios — mercado avícola ecuatoriano

Referencias

- [1] CONAVE — Corporación Nacional de Avicultores del Ecuador. Estadísticas de precios de maíz amarillo y mercado avícola (2024–2025). <https://www.conave.org/>
- [2] *Diario Expreso* (nov. 2025). Reporte de precios del maíz amarillo ($\approx 19,40$ USD por quintal $\equiv 428$ USD/ton $\equiv 0,428$ USD/k). <https://www.expreso.ec/>
- [3] *El Productor*. Costos de producción y precios de venta del pollo en pie en Ecuador. <https://elproductor.com/>

-
- [4] *aviNews*. Coyuntura de precios y costos del sector avícola. <https://avinews.com/>
 - [5] Portal *Pollos.ec* y *Ecuaquímica*. Referencias de precio del pollo en pie y de balanceado por saco. <https://pollos.ec/> ; <https://www.ecuaquimica.com.ec/>

Todos los resultados numéricos de este informe provienen de la ejecución reproducible del cuaderno `pipeline_pollos.ipynb` (semilla 42). Las figuras se generan en `outputs/figures/` y las tablas en `outputs/tablas/`.